

# YADLRetina

## Yet Another Deep Learning Retina

Rubén Crespo Cano

<https://about.me/rubencrespocano>

7 de octubre de 2018

# Autores

## **Universidad de Alicante**

Rubén Crespo-Cano

Antonio Martínez-Álvarez

Sergio Cuenca-Asensi

## **Universidad Miguel Hernández**

Eduardo Fernández

## **Carl von Ossietzky Universität Oldenburg**

Martin Greschner

# Índice

## 1. Introducción

1.1. Motivación

1.2. Retina

1.3. Neuroprótesis visuales

1.4. Objetivo

1.5. Enfoque

## 2. Materiales y Métodos

2.1. Registros electrofisiológicos

2.2. Deep learning

## 3. Resultados y Discusión

## 4. Conclusiones y Trabajo futuro

# INTRODUCCIÓN

# Motivación

# Motivación

Más de 40 millones de personas en el mundo son ciegas.

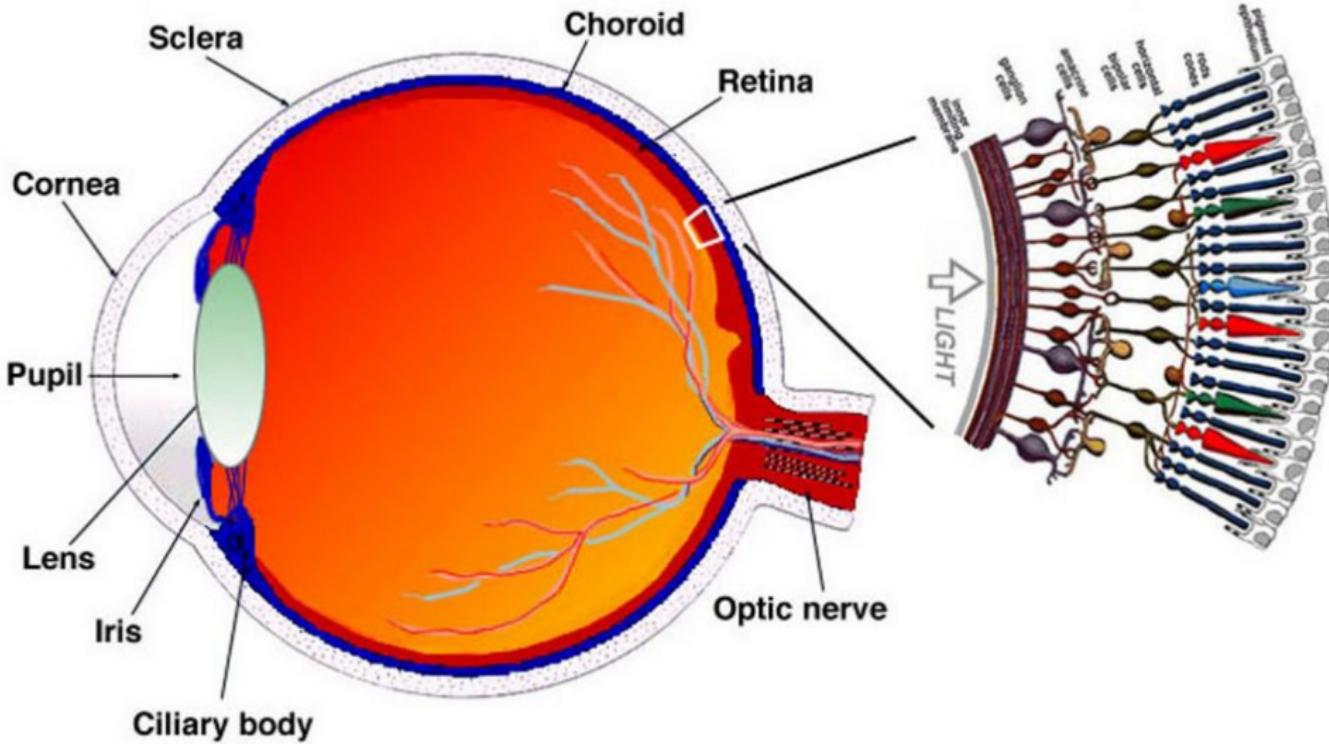
- Pérdida de independencia personal.
- Costes personales y sociales.

Existencia de tratamientos médicos, cirugía y terapias genéticas.

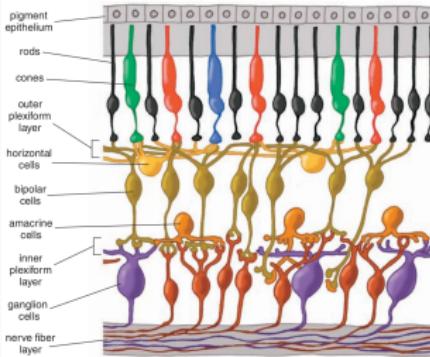
- No útil para AMD, RP, glaucoma, atrofia del nervio óptico, etc.

En tales casos, una *prótesis visual* puede ser la única opción.

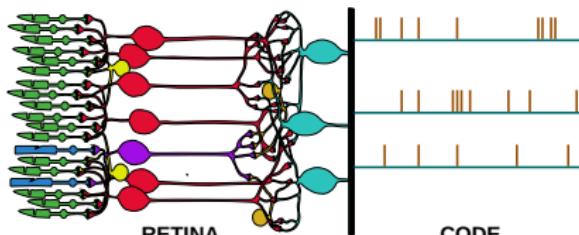
# Retina



# Retina



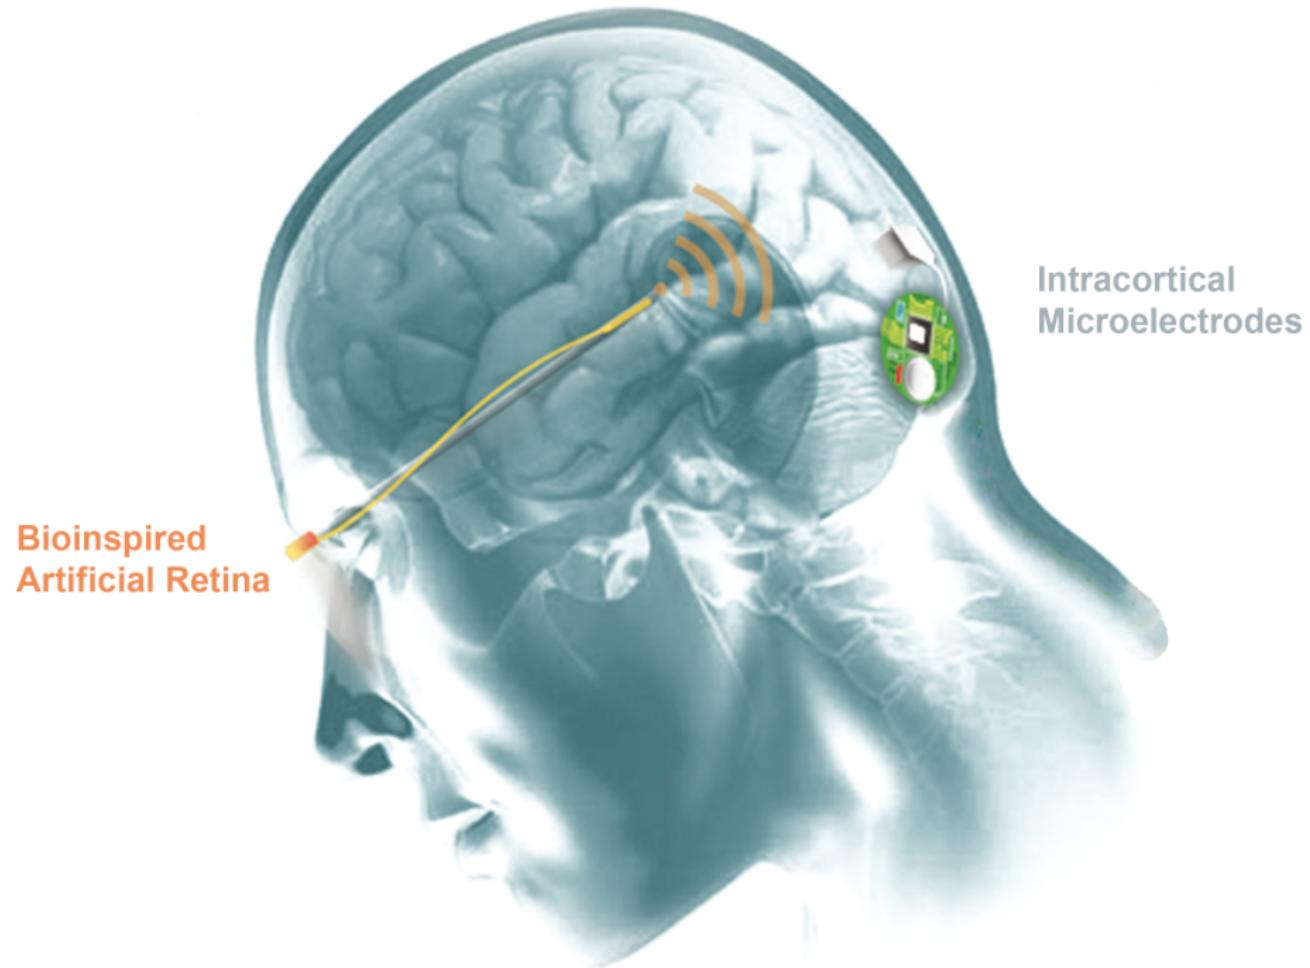
VISUAL INFORMATION



CODE

BRAIN

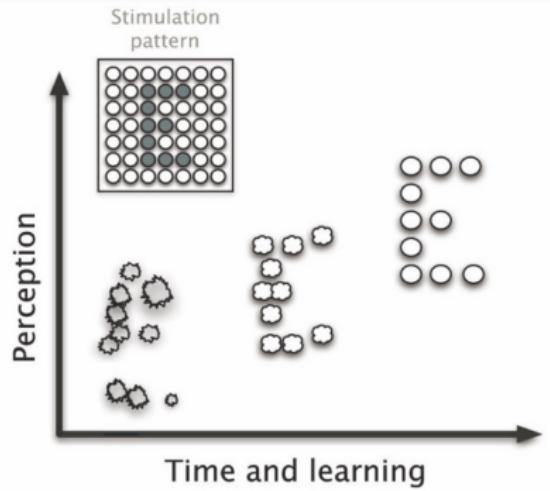
# Neuroprótesis visuales



Bioinspired  
Artificial Retina

Intracortical  
Microelectrodes

# ■ Neuroprótesis cortical



# Objetivo

Comprender las respuestas sensoriales a los estímulos de ruido natural.

## Modelo de retina

- ¿Predicción de respuestas neuronales?
- ¿Correspondencia entre la estructura biológica y el modelo?

## Enfoque

Entrenar redes de aprendizaje profundo para modelar las respuestas de la retina ante estímulos de ruido natural.

Comprobar si los modelos exhiben un comportamiento y una estructura acorde con la disposición de las capas neuronales de la retina.

# MATERIALES Y MÉTODOS

# Registros electrofisiológicos

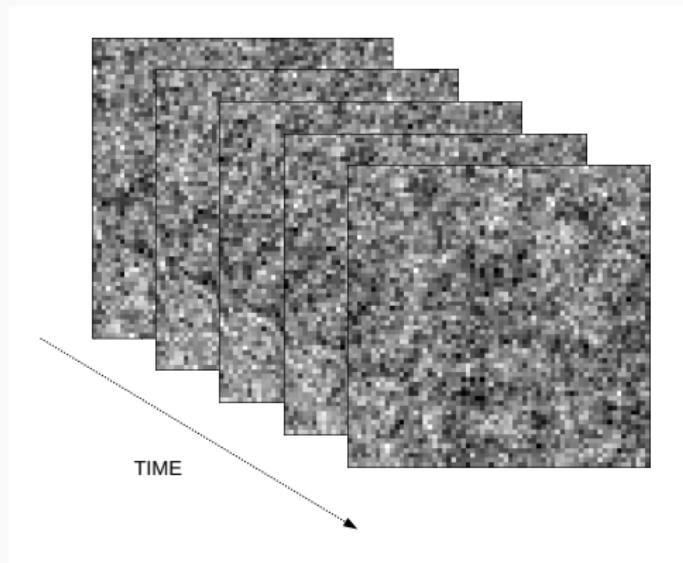


# ■ Estímulo visual

## Estimulación de las retinas

Ruido natural ( $1/f$ ) o ruido rosa.

Tasa de refresco de 120 Hz.



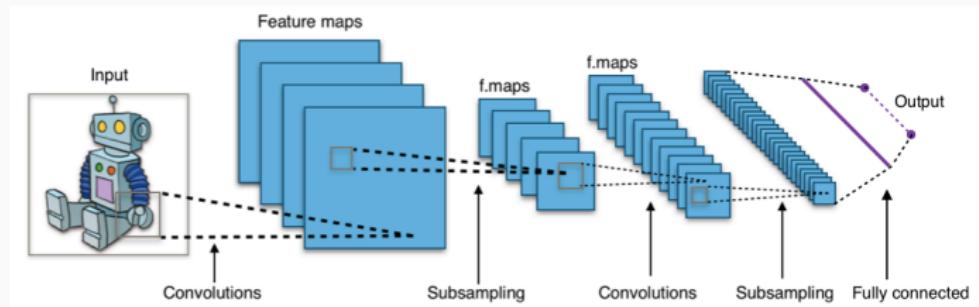
# Demo time

# Deep learning

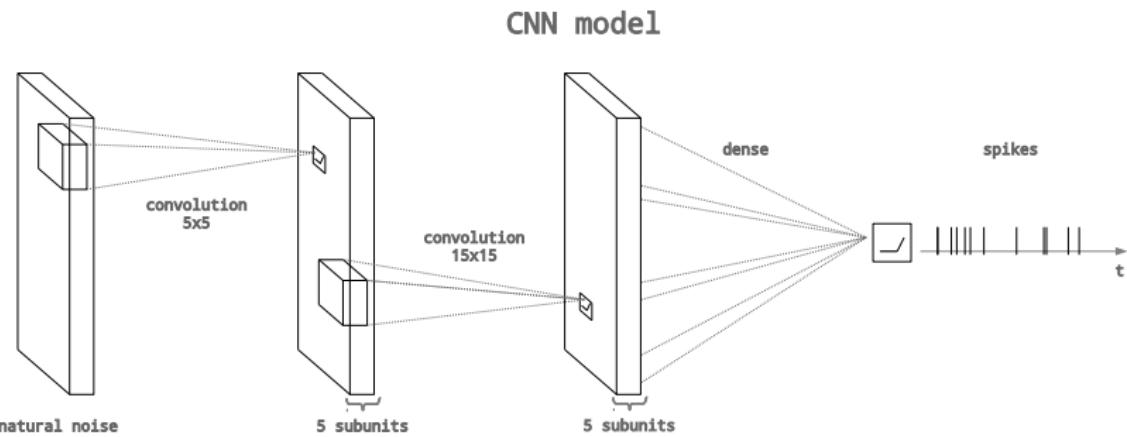
# CNNs

## Convolutional Neural Networks (CNNs).

- Variantes bioinspiradas de MLPs.
- Basadas en la estructura del cortex visual.
- Células sensibles a sub-regiones del campo visual.
- Filtros locales que cubren todo el campo visual.
- Explotar correlación local espacial de las imágenes.
- Entrenamiento: minimizar error entre predicciones y datos.



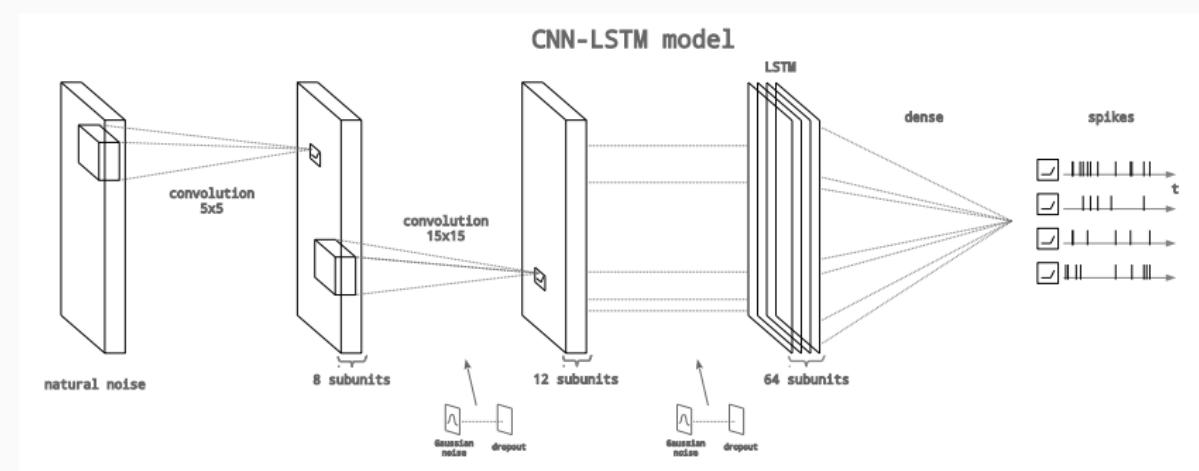
# Modelo individual de células ganglionares.



- Inicialización: Distribución normal de pesos aleatorios.
- Loss function: Binary Crossentropy.
- Optimización: ADAM.
- Time window: 250 ms.
- Filtros espacio-temporales: 5 y 5.
- Kernels: 5px y 15px.
- 100 epochs.
- Early-stopping method (conjunto de validación).
- Parámetros:  $\approx 150,000$ .

# CNN-LSTM

## Modelo población de células ganglionares.



# CNN-LSTM

Inicialización: Distribución normal de pesos aleatorios.

Loss function: Binary Crossentropy.

Optimización: ADAM.

Time window: 250 ms.

Filtros espacio-temporales: 8 y 12.

Kernels: 5px y 15px.

100 epochs.

Early-stopping method (conjunto de validación).

Dropout (overfitting).

Gaussian noise (variabilidad interna).

L2 activity regularizers.

RNN: Long Short-Term Memory (LSTM).

Parámetros:  $\approx 1,500,000$ .



HW y SW



# HW y SW

## Tecnologías

Python (3.6).

TensorFlow (1.8.0 -> 1.10.1).

Keras (2.1.6 -> 2.2.2).

## Infraestructura

HPC cluster (2x Intel XEON 48 GB RAM).

No GPU.

## Código fuente

<https://github.com/rcrespocano/yadlretina>\*

# RESULTADOS Y DISCUSIÓN

# Resultados

## Experimentos:

1. Estudio células individuales.
2. Población de células distintas.

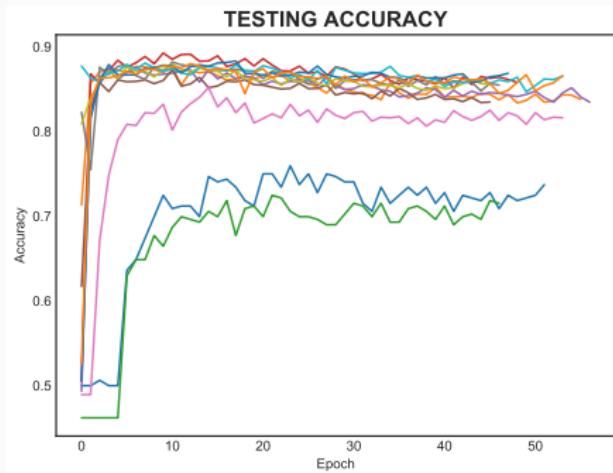
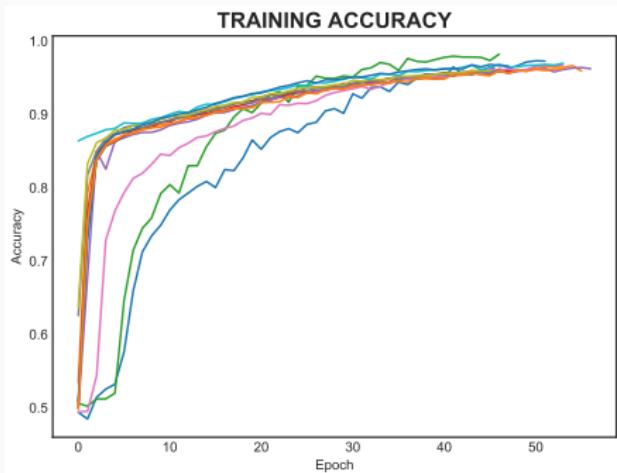
## Data set:

Traning, validation and test sets

50 min., 7 min. y 7 min.

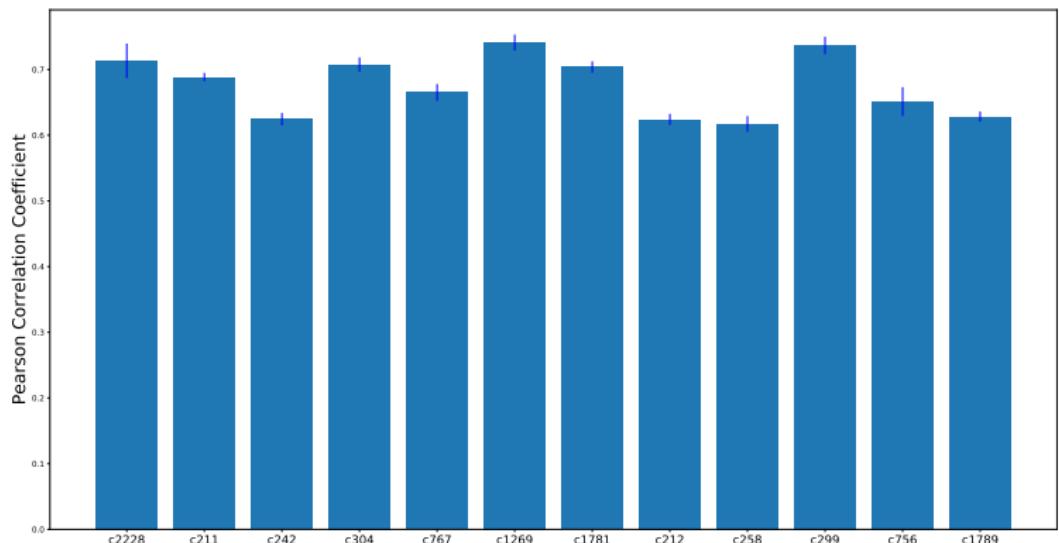
# Resultados

Distribución de la media de la precisión para los conjuntos de entrenamiento y test.



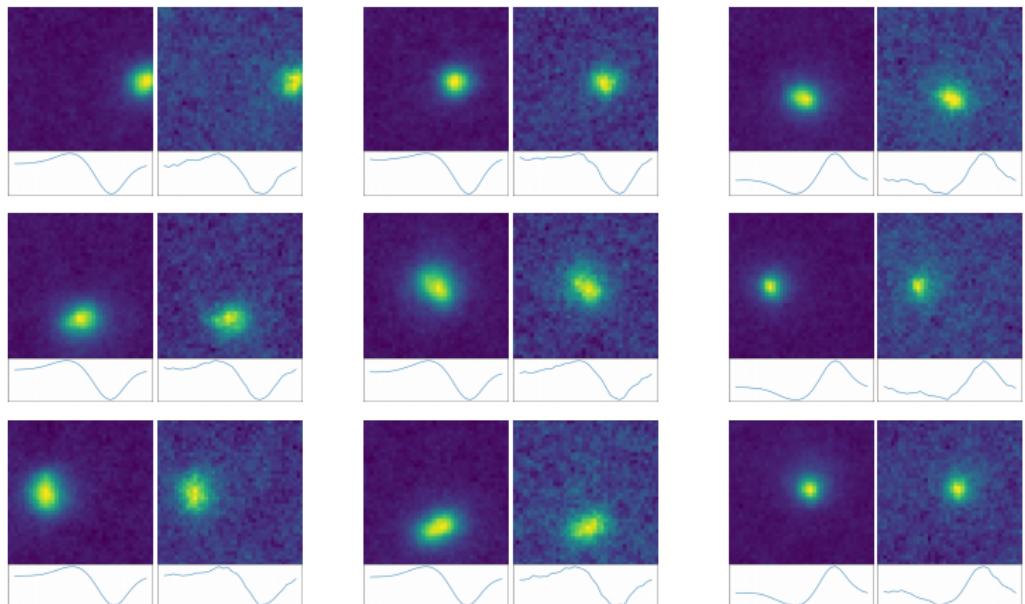
# Resultados

Distribución del coeficiente de correlación de Pearson.



# Resultados

Comparación de los campos receptivos (STA).

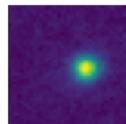


# Resultados

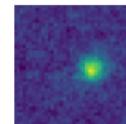
Filtros convolucionales: subunidades localizadas.

**Transient OFF**

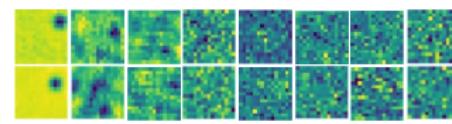
BIO RF



MODEL RF

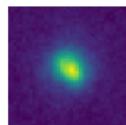


CONV FILTERS

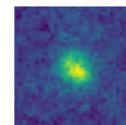


**OFF large fast**

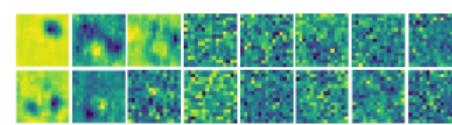
BIO RF



MODEL RF

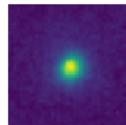


CONV FILTERS

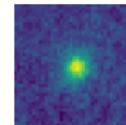


**Transient ON**

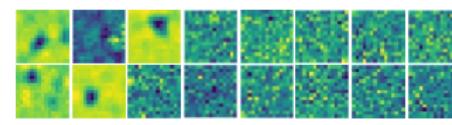
BIO RF



MODEL RF

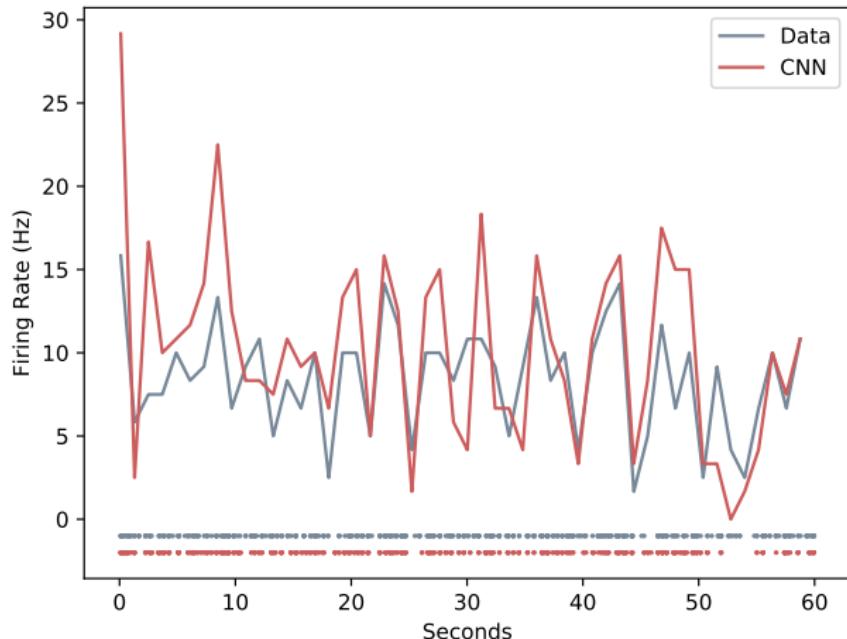


CONV FILTERS



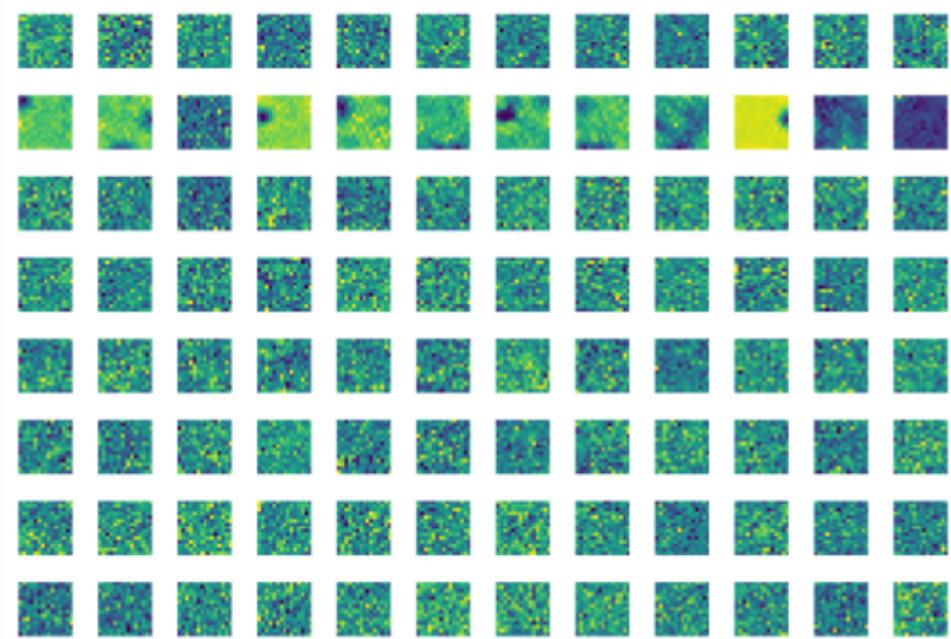
# Resultados

Predicción precisa de respuestas sensoriales ( $PCC \approx 0.70$ ).



# Resultados

Transient OFF, large fast OFF y transient ON.



# CONCLUSIONES Y TRABAJO FUTURO

# CONCLUSIONES

Introducción de dos arquitecturas para codificar neuronas de la retina.

RGCs individuales y población de RGCs.

Reproducción de campos receptivos neuronales.

Predicción de respuestas neuronales ante ruido natural con un coeficiente de correlación de Pearson de hasta 0.70.

Las capas internas de los modelos CNNs son capaces de aprender y revelar componentes subyacentes de la retina.

Este conocimiento puede ser muy útil para abordar el reto del diseño de una neuroprótesis visual.

# ■ TRABAJO FUTURO

1. Escenas naturales.
2. GPU: GeForce GTX 1080 Ti.



A 3D reconstruction of a brain circuit, likely a fly brain, showing a dense network of neurons. The neurons are color-coded, forming a complex web of connections between different brain regions. The reconstruction is set against a background of grey brain tissue and white matter tracts.

**iGracias!**

@rcrespocano

# YADLRetina

## Yet Another Deep Learning Retina

Rubén Crespo Cano

<https://about.me/rubencrespocano>

7 de octubre de 2018